FYP Planning Report：A 股 LLM 交易 Agent 评测与训练场

Project Goal（项目目标）

做一套**公开、可持续运行**的 LLM 交易 Agent 评测与训练设施：用户提交自己的 AI 投资 Agent 配置，它在抗污染的 A 股历史与实时数据上自主研究、决策、下单，最后交出**可核验的成绩与决策档案**。范围上不做实盘交易、通用回测引擎与个股买卖建议。

结题前要达成三条标准：

1. **闭环能演示**：一个配置跑完模拟交易，产出净值曲线与逐笔决策档案；
2. **得出一条有区分度的结论**：模型决策质量接近，行为稳定性（决策翻转率）差异显著；
3. **不确定就说不确定**：样本不足的结论标注「不足以判断」，不给排名。

Significance（项目意义）

What。给 Agent 提供规则正确的 A 股撮合与账户、抗污染数据、全量留痕的决策档案。用户提交模型、提示词、工具集与风控闸门，系统回答**这个配置哪里不可靠**。

Who。主要是已经在用 AI 辅助投资决策的个人（个人研究者、中小机构从业者），他们有投资经验，却没有验证 AI 结论的手段；次要使用者是开发 LLM 交易 Agent 的开发者。

Why。B 站 A 股版 AI 交易横评播放量 **9.5 万**；港大 AI-Trader 把 A 股纳入评测后，六个主流模型**没有一个跑赢 SSE-50 基准**。位置还空着：公开竞技场集中在加密货币和美股，A 股只有一场 40 天赛事；TraderHarness 覆盖 A 股且开源，却只做本地工具。

Problem Statement（问题陈述）

判断结论是否可靠，目前没有依据。现有工具给出结论，却不给可回溯的过程：结论来自哪些数据、重跑会不会变、照着做能不能赚钱，都答不上来。

收益作为唯一标准，信号最弱。TradeRank 九个赛季、2,826 笔交易里只有 **46.2%** 的模型-赛季盈利；A 股实测中六个模型全部跑输基准。样本内夏普好看、样本外由正转负，榜单不报样本内外差异与统计显著性，看不出多少是噪音。

评测协议本身不可信。模型可能用训练记忆认出被测的时间段和公司，等于开卷考试；通用回测框架不以 A 股规则为目标，T+1、涨跌停、集合竞价、除权都要重写。时点泄漏已在 issue 里提出，却没人做成可持续的复算设施。

💡 **本项目要回答的问题**：能否把评测从「比谁赚得多」改成可核验、可复现的绩效测量？

Proposed Solutions（方案与交付物）

方案以 A 股为起点，把评测与训练合到一个场子里，能力分三层。基础能力（入场券）：行情财务数据、个股分析、报告生成、MCP 与 Skill。训练场核心（创新点载体）：撮合引擎、模拟账户、决策留痕、抗污染、多 Agent 同场、指标集。差异化（别人做不了的）：体检报告、工具消融、榜单暴露效应、合成市场。

编号	交付物	验收标准
D1	A 股撮合与账户引擎	T+1、涨跌停、集合竞价、费用、除权规则正确
D2	抗污染数据层	数据出口强制时点掩码，实体匿名化，泄漏审计无发现
D3	决策留痕账本	每次决策的理由、依据、工具调用与结果全量留痕
D4	指标集与体检报告	收益、风险、归因加过程指标；样本内外分开；20 日以下不排名
D5	多 Agent 同场与工具消融	统一资金与规则、账户隔离、实时排名；可做消融
D6	最小闭环 Demo 与开源仓库	建 Agent、参赛、看净值、导出报告端到端跑通

Proposed Timelines（进度安排）

周次从项目启动起算，日历时间取决于学院给定起点；前期调研已完成，产出定位文档 6 份。

阶段	周次	主要工作（含交付物）
一	1-4	技术选型、数据源实测、评测协议定义（技术方案）
二	5-10	数据层、A 股撮合引擎、模拟账户（D1）
三	11-14	决策留痕账本、抗污染机制落地（D2、D3）
四	15-18	指标集、多 Agent 同场、验证实验 3×5×20（D4、D5）
五	19-22	盲跑组实验、Demo 验收、开源发布（D6）

风险已预留：榜单与体检报告分开统计；首版不做合成市场；先占 A 股。不构成投资建议。